

2026년 청소년과학탐구반(YSC) 참가신청서

탐구주제	정렬에서의 Grokking: 일반화 조건과 내부 구조 분석							
탐구분야 (해당분야에 V 표시/택1)	물리	화학	생명·생물	지구·우주	환경	공학·발명	수학	SW·AI
								V
동아리명	EIDOS							
학교정보	학교급	고교						
	학교명	민족사관고등학교						
	소속지역	강원도						
	학교주소	강원특별자치도 횡성군 안흥면 봉화로 800						
지도교사 정보	성명	김준우			생년월일	87.07.22.		
	성별	남			학교전화	070-4742-0128		
	휴대전화	010-6434-8712			e-mail	kju8707@minjok.hs.kr		
	사업 참여실적	-						
참여학생 정보 (2~4인)	성명	생년월일	학년	휴대전화	이메일	성별		
	김서혁	09.12.16	2	010-6669-1216	survibo@gmail.com	남		
	손영우	09.06.03	2	010-2178-9853	isyw963@icloud.com	남		

※ 온라인접수시스템과 참가신청서의 작성내용이 상이한 경우 온라인접수시스템 제출내용을 기준으로 반영 예정이며, 선정 이후 개별 요청 시 수정 가능함

※ 글자수 등 작성기준을 준수하지 않는 경우 추후 탐구주제, 동아리명이 수정 요청될 수 있음

※ 학생 명의의 연락처(휴대전화/메일)가 있는 경우 작성하고, 없는 경우 공란으로 제출
(학부모 등 학생 본인의 것이 아닌 연락처를 대리로 기재 불가)

탐구활동 계획서(요약본)

탐구주제	정렬에서의 Grokking: 일반화 조건과 내부 구조 분석
동아리명	EIDOS
탐구목적	seq2seq Transformer가 정수 수열 정렬 과제에서 먼저 훈련 데이터를 암기한 뒤, 시간이 지나 검증 성능이 급격히 향상되는 지연된 일반화 현상, grokking을 보이는지 확인한다. 또한 정렬 규칙의 복잡도에 따라 일반화 양상이 어떻게 달라지는지 분석하고, 모델 내부 표현을 분석하여 Transformer가 정렬 규칙을 학습하는 방식을 탐구한다. 쉽게 말해, Transformer가 정렬 규칙을 단순히 훈련 예시별로 외우는지, 아니면 충분한 학습 후 처음 보는 수열 조합에도 적용 가능한 일반 규칙으로 학습하는지를 확인하는 것이 목적이다.
탐구방법	Transformer와 grokking 관련 선행연구를 조사한 뒤, 오름차순 정렬, mod 기반 정렬, 최솟값-최댓값 교번 정렬 과제를 수행하는 seq2seq Transformer를 구현한다. 세 정렬은 정렬 키(값 그대로 / mod 기준)와 출력 위치 매핑(단조 / 비단조)이라는 두 축으로 설계하여, 정렬 규칙의 어떤 구조적 속성이 grokking과 연관되는지를 분리 분석한다. 학습 과정에서 훈련 정확도와 검증 정확도를 비교하여 grokking 발현 여부를 확인하고, PCA, Fourier 분석, attention pattern 분석, embedding ablation을 통해 모델 내부 구조를 분석한다. 필요시 지도교사 및 관련 분야 전문가의 자문을 받아 실험 설계와 해석을 보완한다.
탐구내용 및 절차	먼저 정수 수열 데이터셋을 만들고, train/test를 multiset 단위로 분할하여 검증셋의 값 조합이 훈련에 등장하지 않도록 한다. 이후 세 가지 정렬 기준에 대해 Transformer를 학습시켜 훈련 정확도와 검증 정확도의 변화를 기록한다. grokking이 관찰되면 embedding, residual stream, attention pattern을 분석하여 내부 표현 구조를 확인한다. 마지막으로 위치 임베딩(positional embedding)과 토큰 임베딩(token embedding)을 제거하거나 고정하는 실험을 통해 일반화에 중요한 요소를 비교한다.
탐구의 예상 결과 및 활용방안	정렬 규칙이 단순한 값 비교를 넘어 주기적 키 또는 비단조 출력 위치 매핑을 포함할수록 grokking이 더 늦게 발생하거나 발현되지 않을 가능성이 있다. 오름차순 정렬은 비교적 빠르게 일반화될 수 있고, mod 기반 정렬이나 교번 정렬은 더 큰 grokking gap을 보일 것으로 예상된다. 또한 mod 기반 정렬에서는 주기적 내부 표현 구조가, 비단조 정렬에서는 출력 위치 정보에 대한 의존이 더 크게 나타날 것으로 예상된다. 이 탐구는 산업적 응용보다 기초 이해에 기여한다. 첫째, seq2seq 구조 과제에서 grokking과 내부 회로 형성을 분석함으로써 mechanistic interpretability 연구의 분석 대상을 확장한다. 둘째, 정렬 규칙의 구조적 복잡도와 일반화 난이도의 관계에 대한 통제된 증거를 제공해 딥러닝 일반화 이론 연구의 기초 자료가 된다. 셋째, 입력의 대칭성과 위치 임베딩 필요성의 관계에 대한 시사점을 줄 수 있다.

탐구활동 계획서

1 서론

□ 연구 동기

친구와 함께 attention 모델의 원리를 공부하던 중, 인공지능 모델에서 과적합이 항상 발생하는지에 대한 의문이 생겼다. 이후 여러 차례 토론을 거치면서, AI가 단순히 데이터를 암기하는 것을 넘어 일반화 능력을 획득할 수 있는지에 대한 궁금증으로 이어졌고, 그 과정에서 지어진 일반화 현상인 grokking에 관심을 갖게 되었다. 관련 논문을 조사한 결과, 기존 grokking 연구가 주로 modular arithmetic과 같은 단일 토큰 예측 문제에 집중되어 있다는 점을 확인하였다. 이에 단일 토큰 예측을 넘어, 다중 토큰 간의 관계를 일반화하는 것이 가능한지에 흥미를 느끼게 되었다. 오름차순 정렬, mod 기반 정렬, 최솟값-최댓값 교번 정렬 등을 목표로 삼아 연구를 시작하였다.

□ 이론적 배경

○ 관련 개념

- Embedding

Transformer는 이산 토큰을 임베딩(embedding)을 통해 고차원 벡터로 변환하며, 학습 과정에서 값의 크기나 잉여류 구조와 같은 토큰 간의 관계가 벡터 공간의 배치에 반영될 수 있다. 이때 토큰 임베딩은 각 기호를, 위치 임베딩은 수열 내 위치 정보를 인코딩한다. self-attention 연산은 입력 순서에 대해 순열 등변성을 가지므로, 위치 임베딩은 순서 정보를 명시적으로 주입하는 필수 요소이다. 이 두 임베딩의 역할 분리는 본 연구의 연구문제 3 과 직접 연결된다.

- Attention

attention은 수열 내 임의의 두 위치 간 의존 관계를 단일 연산으로 포착하며, 이를 다중 헤드로 수행하는 multi-head attention이 Transformer의 핵심 연산 단위를 구성한다.

- Seq2Seq

Seq2Seq(sequence-to-sequence)은 가변 길이의 입력 수열을 받아 가변 길이의 출력 수열을 생성하는 구조적 틀이다. 단일 토큰을 예측하는 분류 문제와 달리, seq2seq는 출력 수열 전체에 걸쳐 구조적 일관성이 유지되어야 하므로 학습 난이도가 본질적으로 높다. Seq2Seq는 일반적으로 가변 길이 입력과 출력을 다룰 수 있는 구조이지만, 본 연구에서는 실험 통제를 위해 입력 길이를 동일한 고정 길이 N 으로 제한한다.

- Grokking

Grokking은 Power, Burda, Edwards, Babuschkin, and Misra (2022)이 발견한 지연된 일반화(delayed generalization) 현상으로, 신경망이 훈련 데이터에 대해 완전히 과적합한 이후에도 추가적인 최적화를 지속하면 어느 시점에서 검증 정확도가 급격히 상승하는 현상을 가리킨다. 이는 훈련 데이터에 대한 과적합 이후에는 일반화 성능이 개선되기 어렵다는 직관적 이해와 다른 양상을 보여준다.

Nanda, Chan, Lieberum, Smith, and Steinhardt (2023)은 mechanistic interpretability 관점에서 이 현상을 Memorization, Circuit formation, Cleanup의 세 단계로 분리하였다. 학습 초기에는 훈련 데이터를 직접 암기하는 해로 빠르게 수렴하며, 이후 일반화 회로가 가중치 내에서 점진적으로 형성된다. 최종적으로 암기 성분이 소거되면서 일반화 회로만이 잔존하게 되어 검증 정확도가 급등한다. Liu et al.(2022)은 이를 loss landscape 관점에서 분석하여, 훈련 손실과 테스트 손실의 가중치 norm에 대한 형태 불일치(LU mechanism)가 grokking의 근본 원인임을 제시하였다. 암기 해는 일반화 해에 비해 가중치 norm이 크게 유지되므로, weight decay가 모델을 지속적으로 일반화 해 방향으로 유도하는 핵심 기제로 작용한다.

○ 관련 선행연구 조사

- Transformer Model의 기본원리가 되는 연구

- 1) Vaswani et al. (2017)은 “Attention Is All You Need”에서 self-attention을 기반으로 한 Transformer architecture를 제안하였다. 이후 grokking 연구들은 주로 소형 Transformer를 알고리즘에 학습시켜 내부 표현과 일반화 과정을 분석하므로, 이 연구는 본 연구에서 사용하는 model architecture의 기반이 된다.

- grokking 현상을 체계적으로 제시한 연구

- 1) Power et al. (2022)은 “Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets”에서 인공 신경망이 작은 알고리즘 데이터셋을 먼저 암기한 뒤, 긴 optimization 이후 갑자기 일반화를 달성하는 grokking 현상을 보고하였다. 이는 모델이 단순 암기를 넘어 데이터의 기저를 학습할 수 있음을 보여주며, 본 연구의 기반이 된다.
- 2) Nanda et al. (2023)은 “Progress Measures for Grokking via Mechanistic Interpretability”에서 modular addition을 학습한 소형 Transformer가 Fourier basis와 trigonometric identities를 활용해 일반화하는 내부 알고리즘을 reverse engineering하였다. 이 연구는 grokking을 단순한 갑작스러운 성능 변화가 아니라, structured mechanism의 점진적 형성과 memorizing component의 제거가 결합된 과정으로 해석하였다.




Fig 1. Grokking 현상으로 인한 학습량에 따른 Train/Test Accuracy의 변화

- grokking 분석을 다양한 algorithmic task로 확장한 연구

- 1) Chughtai, Chan, and Nanda (2023)은 “A Toy Model of Universality: Reverse Engineering How Networks Learn Group Operations”에서 small neural networks가 finite group composition을 수행할 때 representation theory 기반 알고리즘을 학습할 수 있음을 mechanistic interpretability로 분석하였다. 이 연구는 modular addition 중심의 해석을 group-theoretic algorithmic task로 확장하며, 모델들이 유사한 원리를 학습

할 수 있지만 세부 circuits와 학습 순서는 달라질 수 있음을 보여준다.

- 2) Furuta et al. (2024)은 “Towards Empirical Interpretation of Internal Circuits and Properties in Grokked Transformers on Modular Polynomials”에서 grokking 분석 대상을 modular addition에서 subtraction, multiplication, modular polynomials, multi-task mixture로 확장하였다. 이들은 Fourier Frequency Density(FFD)와 Fourier Coefficient Ratio(FCR)라는 progress measure를 제안하여 operation별 internal representation의 차이를 분석했으며, factorizable polynomials에서는 grokking이 비교적 잘 발생하지만 non-factorizable polynomials에서는 명확한 Fourier pattern이 나타나지 않는 경우가 있음을 보였다.

- Transformer의 sorting task 학습과 내부 구조 분석 연구

- 1) Urdshals and Urdshals (2025)은 “Structure Development in List-Sorting Transformers”에서 one-layer attention-only Transformer가 number list sorting을 학습하는 과정에서 내부 attention 구조가 어떻게 발달하는지 분석하였다. 이 연구는 학습이 끝난 모델의 attention heads가 vocabulary-splitting과 copy-suppression이라는 두 가지 주요 방식으로 조직됨을 보였으며, 본 연구에서 다루는 다양한 정수 정렬 과제에서 모델이 단순 암기를 넘어 어떤 내부 구조를 형성하는지 해석하는 데 참고가 된다.

□ 학술적 가치 및 독창성

○ 학술적 가치

- 신경망의 일반화 메커니즘은 딥러닝 이론의 핵심 미해결 문제 중 하나다. Power et al.(2022)이 발견한 grokking 현상은 신경망이 훈련 데이터를 완전히 암기한 뒤 한참 지나서야 테스트 정확도가 급등하는 지연된 일반화로, 훈련 수렴 이후의 추가 훈련이 일반화를 악화시킨다는 고전적 과적합 이론에 반하며 다수의 후속 연구를 촉발하였다.
- 후속 연구는 주로 modular arithmetic을 중심으로 진행되었다. Nanda et al.(2023)은 modular addition에서 학습된 Transformer가 이산 푸리에 변환과 삼각 항등식으로 덧셈을 원 위의 회전으로 변환하는 알고리즘을 내부적으로 학습함을 reverse engineering으로 밝히고, 훈련 과정을 Memorization–Circuit Formation–Cleanup 세 단계로 구분하였다. Varma et al.(2023)은 이를 일반화 회로와 암기 회로 간 효율성 경쟁으로 설명하였고, Liu, Michaud, and Tegmark(2023)은 Omnigrok을 통해 grokking이 MNIST-그래프 등 다양한 영역에서도 발생함을, Furuta et al.(2024)은 뺄셈·곱셈·다항식 등으로 분석 범위를 확장하였다.
- 그러나 기존 연구는 두 정수 a, b 를 입력받아 $a \cdot b \bmod p$ 를 p 개 클래스 중 하나로 예측하는 단일 토큰 분류에 집중하였다. 수열 전체를 입력받아 재배열된 수열을 출력하는 seq2seq 구조적 변환에서 grokking이 발생하는지, 정렬 기준의 대수적 복잡도에 따라 일반화 양상이 어떻게 달라지는지는 거의 탐구되지 않았다. 정렬은 원소 간 순서 관계를 내재하여 단순한 입출력 대응을 넘어 수열 전체의 구조를 파악해야 한다는 점에서 기존 연구와 본질적으로 다른 구조를 가진다. 또한 $(\bmod m)$ 오름차순이나 최솟값-최댓값 교번 정렬처럼 일부 기준은 잉여류 구조를 정렬 키로 내포하여 modular arithmetic과 주기적 구조를 공유하며, 본 연구는 이 유사성이 모델 내부 표현에서 실제로 재현되는지를 검증한다. 나아가 위치 임베딩과 토큰 임베딩의 역할, 유효 표현 차원 수를 분석하여 Transformer 내부 표현 학습 메커니즘에 대한 이해를 심화한다.

○ 연구의 독창성

- 본 연구는 단일 토큰 분류에 집중한 기존 연구와 달리, 길이 N 의 수열을 입력받아 재배열된 수열 전체를 출력하는 seq2seq 구조, 즉 출력이 구조화된 수열인 grokking 사례를 다룬다.
- 특히 정렬 기준을 서로 독립적인 두 축에서 설계한다. 첫째는 정렬 키의 대수적 구조로, 값을 그대로 쓰는 항등 키(오름차순)에서 잉여류 구조를 내포하는 (mod m) 기반 키로 확장한다. 둘째는 순위에서 출력 위치로의 매핑 구조로, 단조 매핑(오름차순)에서 비단조 매핑(최솟값-최댓값 교번)으로 확장한다. 단일 대수 구조에 한정되었던 기존 연구와 달리, 두 축을 분리하여 정렬 규칙의 어떤 구조적 속성이 grokking과 연관되는지를 귀납적으로 탐색한다.
- 또한 encoder-decoder 각각에서 위치/토큰 임베딩 중 무엇이 일반화에 결정적인지, 표현의 유효 차원 수는 몇 개인지를 분석하여 현상 확인을 넘어 내부 구조 규명을 시도한다. 정렬 함수는 입력 순서에 불변(permutation invariant)이지만 출력은 순서를 가진다는 비대칭성에 주목하여, encoder와 decoder에서 위치 임베딩의 필요성이 다르게 나타나는지를 분리 검증한다. 단층 attention-only Transformer의 학습 완료 후 attention 구조를 분석한 Urdshals and Urdshals(2025)와 달리, 본 연구는 grokking 발현 여부와 그 과정에서 내부 표현 변화에 초점을 둔다.

2 연구 문제

□ [연구 문제 1] Seq2Seq 정렬에서 Grokking이 발현되는가, 그리고 정렬 규칙의 구조는 그 발현 양상에 어떤 영향을 주는가?

기존 grokking 연구는 단일 토큰 분류(modular arithmetic)에 집중되어 있어, 출력이 순서를 갖는 seq2seq 구조적 변환에서도 grokking이 동일하게 발현되는지는 아직 규명되지 않았다. 본 연구는 먼저 정렬 과제에서 grokking, 즉 훈련 정확도가 포화된 이후 한참 뒤에 검증 정확도가 급등하는 지연된 일반화가 실제로 발현되는지를 확인한다. 이를 위해 서로 독립적인 두 축에서 정렬 기준을 설계한다. 정렬 키 축에서는 값을 그대로 사용하는 전순서 기반 오름차순 정렬과 mod m 잉여류 체계를 키로 내포하는 (mod m)에 대한 오름차순 정렬을, 출력 위치 매핑 축에서는 단조 매핑(오름차순)과 비단조 매핑(최솟값-최댓값 교번 정렬)을 둔다. 각 기준에 대해 모델 크기·learning rate·weight decay·입력 길이 N ·정수 크기 p ·train fraction을 고정한 통제된 조건에서 5개 이상의 시드로 훈련시킨다. 정렬 기준 간 내재적 난이도 차이를 고려하여, raw step 수뿐 아니라 훈련 정확도 포화 시점으로 정규화한 상대적 grokking gap도 함께 확인한다. 단, grokking은 hyperparameter와 weight decay에 민감하므로 발현되지 않을 수 있으며, 이 경우 "정렬 과제에서는 grokking이 관찰되지 않는다" 또는 "어떤 구조에서 grokking이 관찰되지 않는가"로 해석한다. 나아가 단일 토큰 분류에서 관찰된 memorization → circuit formation → cleanup의 전이가 출력 시퀀스 전체의 일관성이 요구되는 seq2seq 정렬에서도 동일하게 재현되는지를 검토하고, 정렬 규칙의 구조(정렬 키 / 위치 매핑)에 따라 발현 여부와 시점이 어떻게 달라지는지를 비교한다.

□ [연구 문제 2] grokking 이후 모델의 내부 표현은 어떤 구조를 가지는가?

Nanda et al.(2023)은 modular addition에서 grokking이 완료된 모델이 푸리에 기저를 활용한 소수의 주파수 성분만으로 연산을 수행함을 보였다. 이는 일반화 이후 모델의 내부 표현이 과제 구조에 부합하는 저차원 기하학적 구조로 수렴할 수 있음을 시사한다. 다만 modular addition의 푸리에 구조는 순환군 상의 합성 연산에서 비롯되는 반면, 정렬은 원소 간 비교와 라우팅을 핵심으로 하므로 동일한 저차원 수렴이 나타나지 않을 수 있다. 따라서 본 연구는 저차원 수렴을 전제하지 않고, grokking 완료 모델의 내부 표현이 어떤 구조를 갖는지를 다음 단계로 탐색한다. 먼저 토큰 임베딩 행렬과 residual stream 활성화에 PCA를 적용하여 유효 차원 수를 측정하고, 정렬 키에 주기 구조가 도입된 기준에서는 이산 푸리에 변환으로 주기성이 표현에 반영되는지를 검사한다. 푸리에 구조가 나타나지 않을 경우 군집 구조, 계층적 선형 구조, 잉여류에 대한 선형 분리 가능성 순으로 대안적 구조를 탐색한다.

□ [연구 문제 3] seq2seq 정렬에서 위치 임베딩과 토큰 임베딩은 일반화에 대해 각각 어떠한 기여를 가지는가?

정렬은 원소의 값뿐 아니라 출력 시퀀스 내 위치 관계를 동시에 학습해야 하므로, 토큰 임베딩과 위치 임베딩이 일반화에 기여하는 방식이 분류와 본질적으로 다를 수 있다. 정렬 함수는 입력 순서에 대해 불변(permutation invariant)이지만 출력은 순서를 가진다는 비대칭성에 주목한다. 이로부터 encoder의 위치 임베딩은 일반화에 불필요하거나 오히려 해로울 수 있는 반면, decoder의 위치 임베딩은 출력 순서를 결정하는 데 기여한다는 가설을 세운다. 다만 decoder의 의존도는 정렬 기준에 따라 다를 수 있다. 단조 매핑(오름차순)은 "지금까지 출력한 값 중 최댓값"과 같은 내용 기반 상태만으로 다음 토큰을 결정할 수 있어 위치 임베딩 없이도 학습될 여지가 있는 반면, 비단조 매핑(교번 정렬)은 출력 위치의 홀짝에 규칙이 의존하므로 절대 위치 정보가 결정적일 것으로 예상된다. 이를 검증하기 위해 학습형 절대 위치 임베딩을 기준선으로 하여 위치 임베딩을 encoder/decoder로 분리해 제거하는 ablation을 수행하고, 조건 간 대비를 통해 가설을 직접 검증한다. 특히 정렬 기준에 따라 두 임베딩의 상대적 기여도가 달라지는지를 함께 분석함으로써, 정렬 규칙의 구조가 표현 학습 메커니즘에 어떻게 반영되는지를 확인한다.

3 연구 내용

□ 연구 개요

연구는 세 단계로 구성된다. 첫째(연구 문제 1), 정렬 키와 출력 위치 매핑이라는 두 독립적인 축에서 설계한 정렬 기준들에 대해 동일한 조건으로 Transformer를 훈련하여, grokking의 발현 여부와 발현 시점, 그리고 일반화 지연의 정도(grokking gap)를 비교한다. 둘째(연구 문제 2), grokking이 완료된 모델의 내부 표현을 추출하여 유효 차원 수와 그 기하학적·회로적 구조를 분석한다. 셋째(연구 문제 3), 위치 임베딩과 토큰 임베딩에 대한 ablation을 통해 각 표현 요소가 일반화에 기여하는 방식을 정렬 기준별로 분리 측정한다.

□ 연구 구성

- 정렬 과제 및 데이터셋 설계

- 입력·출력의 정의

어휘(값) 집합을 $V = \{0, 1, \dots, p-1\}$ 로 둔다. 즉 수열에 등장하는 정수는 0부터 $p-1$ 까지이다. 입력은 이 집합에서 뽑은 길이 N 의 정수 수열 $x = (x_1, \dots, x_N) \in V^N$ 이며, 같은 값이 중복될 수 있다. 정렬 결과는 원소의 순서가 아니라 어떤 값들이 들어 있는지에만 의존하므로, 입력은 순서 없는 모음(multiset)으로 간주한다. 출력은 정해진 정렬 기준에 따라 이 수열을 재배열한 결과이다.

입력·출력은 BOS-EOS-SEP 특수 토큰으로 경계를 표시해 토큰화하고, decoder가 자기회귀적으로 생성한다. 손실은 출력 위치 전체의 cross-entropy 합이다.

- 세 가지 정렬 기준

정렬 기준은 서로 독립적인 두 축에서 설계한다. 정렬 키 축은 값을 그대로 쓰는지(항등) 가공하는지(주기)를, 출력 위치 매핑 축은 순위와 출력 위치의 대응이 단조인지 비단조인지를 가른다. 세 기준은 입력 분포와 입출력 길이를 동일하게 공유하므로, 차이는 오직 정렬 규칙의 구조에서만 비롯된다.

기준 A — 오름차순 정렬 (키: 항등 / 매핑: 단조)

값을 오름차순으로 정렬한다. 예: $(3, 1, 4, 1, 5) \rightarrow (1, 1, 3, 4, 5)$. 핵심 구조는 원소 간 비교이며, grokking 발현의 기준선 역할을 한다.

기준 B — 잉여류 기반 정렬 (키: 주기 / 매핑: 단조)

1차 키를 $x \pmod m$, 2차 키를 x 로 하여 오름차순 정렬한다(잉여류가 작은 원소가 먼저, 같은 잉여류 안에서는 오름차순). 예: $m=3$ 일 때 $(3, 1, 4, 1, 5) \rightarrow (3, 1, 1, 4, 5)$. 정렬 키에 $\pmod m$ 의 잉여류 체계가 내포된다. 본 연구는 이 기준에서 내부 표현이 modular arithmetic 연구(Nanda et al., 2023)의 Fourier형 주기 구조를 재현하는지를 검증 대상으로 하되, 재현되지 않을 가능성도 함께 분석한다.

기준 C — 최솟값-최댓값 교번 정렬 (키: 항등 / 매핑: 비단조)

최솟값·최댓값·2번째 최솟값·2번째 최댓값... 순으로 교번 재배열한다. 예: $(3, 1, 4, 1, 5) \rightarrow (1, 5, 1, 4, 3)$. 순위와 출력 위치가 단조 관계를 이루지 않으므로, 모델은 값의 순위(rank)와 출력 위치 간의 비단조 대응을 학습해야 한다.

- Grokking 관찰을 위한 데이터

grokking은 (i) 훈련셋에 대한 암기가 가능하면서, (ii) 일반화가 자연되는 환경에서만 관찰된다. 입력 공간 $|V|^N$ 이 조합적으로 폭발하면 암기가 불가능해져 grokking 대신 일반적인 학습이 일어나므로, 본 연구는 정수 크기와 길이를 작게 제한한다. 구체적으로 $V \approx 10-12$, $N \approx 5-6$ 을 후보로 하면 입력 공간이 약 10^5-10^6 규모가 되어, 소규모 Transformer가 훈련셋을 암기할 수 있으면서 동시에 일반화를 측정할 검증셋도 확보된다. 다만 구체적인 수치는 본 실험에서 충분히 변경될 수 있다.

전체 입력 집합을 일정 비율만 훈련셋으로, 나머지를 검증셋으로 무작위 분할한다. 단, 정렬 출력은 입력의 순서가 아니라 multiset에만 의존하므로, 분할은 multiset 단위로 수행한다. 이렇게 하면 검증셋의 어떤 입력도 그 순열이 훈련셋에 등장하지 않아, 모델이 처음 보는 값 조합에 대한 일반화를 측정하게 된다.

train fraction은 0.3–0.8 범위에서 변화시켜 비율에 따른 grokking이 나타나는 정도를 조사한다. 이 비율은 grokking 발현 시점에 결정적 영향을 미치므로, 모든 정렬 기준에서 동일한 비율 집합을 사용하여 비교의 합리성을 확보한다.

○ 모델 구조 및 학습 설정

모델은 Vaswani et al.(2017)의 encoder–decoder Transformer를 소규모로 구성한다(단, 연구 진행 과정에 따라 기반으로 하는 Transformer는 변경할 수 있다). 최적화는 grokking 유도에 핵심적인 weight decay를 강하게 적용한 AdamW를 사용하며, full-batch 또는 large batch로 최대 10^6 step까지 장기 학습한다. weight decay는 암기 해(큰 가중치 norm)에서 일반화 해(작은 norm)로 모델을 유도하는 기제(Liu et al., 2022의 LU mechanism)이므로, 그 강도가 grokking 발현에 미치는 영향을 별도로 분석한다. 이때 단일 고정값으로 비교하면 기준별 최적 weight decay가 달라 일부 기준에서만 grokking이 억제될 수 있으므로, weight decay 축에 걸친 phase diagram(Liu et al., 2022; Liu et al., 2023)으로 각 기준의 grokking 발현 영역을 비교한다. 어느 기준이 더 넓은 weight decay 구간에서 grokking하는지가 발현 난이도의 더 안정적인 지표가 된다.

정렬 기준 간 비교의 공정성을 위해 model size, learning rate, batch size, 초기화 스케일, 입력 길이 N , 정수 크기 p , train fraction을 모든 조건에서 동일하게 고정한다. 단 weight decay는 위와 같이 의도적으로 조정하는 분석 대상 변인이므로 고정 대상에서 제외한다. grokking 발현 시점은 무작위 시드에 따른 분산이 크므로, 각 (정렬 기준 $\times$ 설정) 조합에 대해 5개 이상의 시드로 반복 실험하여 분포로 기록한다.

4 연구 방법 및 예상 결과

□ 연구 방법

○ [연구 문제 1] 정렬 기준별 grokking 발현·수렴 비교

각 정렬 기준에 대해 훈련 step에 따른 훈련/검증 정확도 곡선을 기록한다. seq2seq 과제이므로 두 가지 정확도를 함께 측정한다: 출력 시퀀스 전체가 정확히 일치하는 시퀀스 단위 exact-match 정확도와, 위치별 토큰이 일치하는 토큰 단위 정확도이다. 전자는 전체 시퀀스 수준의 일반화 여부를, 후자는 부분적인 학습 진행을 포착한다. 검증 정확도는 teacher forcing 없이 자기회귀 decoding으로 측정하여 실제 생성 성능을 반영하도록 한다.

grokking 발현의 조작적 정의: 훈련 정확도가 포화(예: 99.5% 이상)된 step t_{train} 과, 검증 exact-match 정확도가 임계값(예: 95%)을 처음 초과하는 step t_{val} 을 각각 확인하고, 그 간격 $\Delta = t_{\text{val}} - t_{\text{train}}$ 을 grokking gap으로 정의한다. Δ 가 클수록 일반화가 더 지연됨을 의미한다. 최대 step까지 검증 정확도가 임계값에 도달하지 못한 경우는 grokking이 관찰되지 않은 것으로 기록한다.

교란변인 분리:

정렬 기준에 따른 알고리즘 난이도가 상이하므로, raw step 수의 단순 비교는 정렬 규칙의 구조적 효과와 알고리즘 난이도를 혼동할 위험이 있다. 이를 완화하기 위해 (i) 훈련 정확도가 포화되는 시점으로 정규화한 상대적 gap, (ii) 동일 train fraction에서의 발

현 여부(이진 결과)를 함께 조사한다.

통계 처리:

발현 시점(time-to-grok)은 일부 시드가 끝까지 grok하지 않는 중도절단 데이터이므로, 단순 평균 비교 대신 Kaplan-Meier 생존곡선으로 시각화하고 기준 간 차이는 log-rank 검정으로 평가한다. 시드 간 분산은 박스플롯으로 함께 제시한다. 이를 통해 "정렬 규칙의 어떤 구조적 속성이 grokking을 더 어렵게/쉽게 만드는가"를 귀납적으로 탐색한다.

○ [연구 문제 2] grokking 이후 내부 표현 분석

grokking이 완료된 모델에서 토큰 임베딩 행렬과 residual stream 활성을 추출하여 내부 표현의 구조를 분석한다. residual stream은 분석 대상 층과 위치를 명시하여 추출하며, 기본적으로 encoder 마지막 층의 각 입력 위치 활성을 사용한다.

유효 차원 측정:

표현 행렬에 PCA를 적용하여, 누적 분산의 일정 비율(예: 90%, 95%)을 설명하는 데 필요한 주성분 수, 그리고 participation ratio PR 를 계산하여 표현이 얼마나 저차원으로 압축되었는지를 정량화한다.

기준별 예상 구조 및 검증:

기준 A(키: 항등 / 매핑: 단조)에서는 토큰 임베딩이 값의 크기에 따라 일렬로 배열되는 거의 1차원적 수직선 구조를 예상한다.

기준 B(키: 주기 / 매핑: 단조)에서는 토큰 임베딩에 이산 푸리에 변환(DFT)을 적용하여 modular arithmetic에서 관찰된 것과 같은 주기 구조가 나타나는지를 검사하고, Furuta et al.(2024)의 Fourier Frequency Density(FFD)를 progress measure로 활용하여 정량 비교한다. 단, 작은 V 에서는 모델이 $x \bmod m$ 을 산술적으로 계산하지 않고 lookup으로 처리해 주기 구조가 나타나지 않을 수 있다. 이 경우 군집 구조(잉여류별 임베딩 군집화), 계층적 선형 구조(잉여류별 평행 직선), 잉여류에 대한 선형 분리 가능성(linear probing) 순으로 대안적 구조를 탐색한다.

기준 C(키: 항등 / 매핑: 비단조)에서는 값의 순위와 출력 위치 간 비단조 대응이 표현에 어떻게 인코딩되는지를 분석한다.

- Attention 회로 분석

정렬에서는 표현이 임베딩 기하뿐 아니라 attention 패턴에 나타날 수 있으므로, 각 출력 위치가 어느 입력을 참조하는지를 분석한다. Urdshals and Urdshals(2025)가 보고한 vocabulary-splitting-copy-suppression 패턴이 나타나는지를 확인하여, 표현이 임베딩 기하와 attention 회로 중 어느 쪽에 주로 의존하는지 평가한다.

○ [연구 문제 3] Embedding Ablation

정렬은 입력 원소의 값뿐 아니라 출력 시퀀스 내 위치 관계를 동시에 학습해야 하므로, 두 종류 임베딩의 역할이 단일 토큰 분류와 본질적으로 다를 수 있다. 정렬 함수는 입력 순서에 대해 불변이지만 출력은 순서를 가진다는 비대칭성이 존재한다. 검증

대상 가설은 연구문제 3에서 진술한 바와 같다(encoder PE는 불필요/유해, decoder PE는 출력 순서에 기여하며, 그 의존도는 단조 기준에서 약하고 비단조 기준에서 결정적이라는 예측). 이를 직접 검증하기 위해 다음 조건들을 비교한다.

- (C0) 전체 모델: 학습형 토큰 + 학습형 절대 위치 임베딩(기준).
- (C1) 위치 임베딩 전면 제거.
- (C2) encoder 위치 임베딩만 제거.
- (C3) decoder 위치 임베딩만 제거.
- (C4) 토큰 임베딩을 고정(one-hot 또는 무작위 고정)으로 대체.

각 조건에서 grokking 발현 여부, grokking gap, 최종 exact-match 정확도를 측정한다. C2와 C3의 대비를 통해 위의 비대칭 가설을 직접 검증하며, C4를 통해 학습형 토큰 임베딩이 일반화에 필수적인지를 확인한다. 나아가 동일한 ablation을 세 정렬 기준 각각에 적용하여, 각 임베딩의 상대적 기여도가 정렬 규칙의 구조에 따라 달라지는지를 분석한다. 잉여류 기준에서는 주기 구조를 인코딩하는 토큰 임베딩이, 교번 기준에서는 출력 위치를 인코딩하는 decoder 위치 임베딩이 상대적으로 더 결정적일 것으로 예상한다.

조건 간(C0~C4) 최종 exact-match 정확도와 grokking 발현 여부의 차이는 시드 표본에 대한 비모수 검정으로 평가하며, 발현 시점 비교에는 *연구문제1* 과 동일하게 Kaplan–Meier 생존곡선과 log-rank 검정을 적용한다. 특히 C2(encoder PE 제거)와 C3(decoder PE 제거)의 대비를 정렬 기준별로 비교하여, PE 비대칭 가설이 기준에 따라 어떻게 달라지는지를 확인한다.

□ 예상 결과

- 두 축(주기 키·비단조 매핑) 모두 기준선(A)보다 grokking이 더 지연되거나 더 좁은 weight decay 구간에서만 발현될 것이다.
- 기준 B에서 Fourier 주기 구조가 재현될 수도, 잉여류별 군집/계층 구조로 나타날 수도 있다.
- decoder PE가 더 결정적이며, 그 의존도는 비단조(C) 기준에서 가장 클 것이다.

5 주요일정

일정	내용	비고
07월 말	연구 준비: 기존 연구에서 사용된 Transformer model 탐색 및 이해	
08월 초	Transformer model 제작: 기존 연구의 Transformer model을 본 연구에 맞는 seq2seq 구조로 변경	
08월 말	예비 실험1: 제작한 Transformer model 테스트 및 수정 & Grokking 현상 유무 확인	
09월 초	예비 실험2: 제작한 Transformer model 테스트 및 수정 & Grokking 현상 유무 확인	
09월 말	본 실험1: 연구문제 해결을 위한 실험 진행	
10월 초	본 실험2: 연구문제 해결을 위한 실험 진행	
10월 말	내부 구조 분석: PCA, Fourier 분석, attention pattern 분석, embedding ablation을 이용한 모델 내부 구조 분석	

6 참고문헌

- Chughtai, B., Chan, L., & Nanda, N. (2023). A toy model of universality: Reverse engineering how networks learn group operations. In Proceedings of the 40th International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 202, pp. 6243–6267). PMLR.
- Furuta, H., Minegishi, G., Iwasawa, Y., & Matsuo, Y. (2024). Towards empirical interpretation of internal circuits and properties in grokked Transformers on modular polynomials. Transactions on Machine Learning Research.
- Liu, Z., Kitouni, O., Nolte, N. S., Michaud, E. J., Tegmark, M., & Williams, M. (2022). Towards understanding grokking: An effective theory of representation learning. In Advances in Neural Information Processing Systems (Vol. 35, pp. 34651–34663). Curran Associates, Inc.
- Liu, Z., Michaud, E. J., & Tegmark, M. (2023). Omnigrok: Grokking beyond algorithmic data. In International Conference on Learning Representations.
- Nanda, N., Chan, L., Lieberum, T., Smith, J., & Steinhardt, J. (2023). Progress measures for grokking via mechanistic interpretability. In International Conference on Learning Representations.
- Power, A., Burda, Y., Edwards, H., Babuschkin, I., & Misra, V. (2022). Grokking: Generalization beyond overfitting on small algorithmic datasets. arXiv preprint arXiv:2201.02177.
- Urdshals, E., & Urdshals, J. (2025). Structure development in list-sorting Transformers. arXiv preprint arXiv:2501.18666.
- Varma, V., Shah, R., Kenton, Z., Kramár, J., & Kumar, R. (2023). Explaining grokking through circuit efficiency. arXiv preprint arXiv:2309.02390.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (Vol. 30, pp. 5998–6008). Curran Associates, Inc.

연구활동비 집행 계획서

(단위 : 원)

관리목	소요예산	비율(%)	지출계획 및 산출근거
전문가활용비			
회의비			
출장비			
소프트웨어 활용비	267,600	26.21%	○ 데이터베이스 비용 - \$(25+19.17)/month x 4개월 = 267,600원
클라우드 컴퓨팅 서비스 활용비	747,000	73.17%	○ 외부 GPU 이용료 - \$0.69/hr x 300시간 = 322,700원 ○ 외부 GPU 스토리지 - \$0.07/GB/month x 1000 x 4개월 = 424,300원
연구실 운영비			
연구인력지원비			
기타 경비	6,300	0.62%	○ A4 용지 - 6,300원 x 1개 = 6,300
총액	1,020,900	100	

[양식4] 개인정보 제공·활용 동의서 및 연구윤리 서약서

1. 개인정보 수집·이용 동의서					
한국과학창의재단은 개인정보보호법에 의거 「2026년 청소년과학탐구반(YSC)」 참가팀 모집과 관련, 다음 각 호의 정보를 수집·이용하고 있습니다.					
1. 수집·이용목적 - 참가팀 선정, 보고서 제출 등 과제의 선정·평가 및 관리 - 과학탐구활동 수행의 적법·적정성 평가를 위한 관리					
2. 수집하는 개인정보의 항목(필수) - (학생) 성명, 소속학교(학년), 성별, 휴대전화번호, 이메일(전자우편) - (교사) 성명, 소속학교(직급), 성별, 휴대전화번호, 이메일(전자우편)					
3. 개인정보 보유·이용 기간: 「2026년 청소년과학탐구반(YSC)」 신청일로부터 5년 상기 개인정보 수집에 대해 거부할 수 있으며, 거부시 선정 명단에서 제외될 수 있습니다.					
개인정보 수집·이용에 동의하십니까? ☒ 동의함 ☐ 동의하지 않음					
2. 개인정보 제3자 제공 동의서					
<개인정보 제3자 제공에 관한 사항>					
1. 개인정보를 제공받는 자 (※관련 사항은 메일 등으로 개별 안내) - 2026년 청소년과학탐구반(YSC) 지역별 관리주체 (국립광주과학관 강원연구개발지원단 국립군산대학교 제주과학문화협회) - 2026년 청소년 과학탐구대회 행사 운영대행사					
2. 개인정보 제공 목적 - 2026년 청소년과학탐구반(YSC) 운영지원 및 사업관리					
3. 개인정보 제공 항목 - (학생) 성명, 소속학교(학년), 성별, 휴대전화번호, 이메일(전자우편) - (교사) 성명, 소속학교(직급), 성별, 휴대전화번호, 이메일(전자우편)					
3. 개인정보 보유·이용 기간: 「2026년 청소년과학탐구반(YSC)」 종료일로부터 1년 상기 개인정보 제공에 대해 거부할 수 있으며, 거부 시 선정 명단에서 제외될 수 있습니다.					
개인정보 제3자 제공에 동의하십니까? ☒ 동의함 ☐ 동의하지 않음					
3. 연구윤리 준수 서약서					
본인은 한국과학창의재단 「2026년 청소년과학탐구반(YSC)」 지원 및 탐구수행 전 과정에서 아래 사항을 준수할 것을 서약합니다.					
1. 탐구활동 계획서에 의거하여 성실히 연구를 수행할 것을 서약합니다.					
2. 제출한 탐구활동 계획서는 2026년 청소년과학탐구반(YSC) 지원을 위하여 탐구반 지도교사 및 학생들이 독자적으로 수립하였으며, 타 과제에 대한 표절 또는 모방 등 윤리에 어긋나는 내용을 포함하지 않습니다.					
3. 활동수행 시 연구윤리와 연구 수행을 위한 관련 규정 및 지침을 준수하겠습니다.					
4. 제출한 탐구계획은 독창적인 것으로서 그 연구수행 결과물을 출품하여 수상한 바가 없으며, 한국 과학창의재단 또는 다른 기관으로부터 중복 지원을 받지 않습니다.					
5. 본 지도교사는 재단이 주관하는 탐구반 관련 행사 참여에 적극 협조하겠습니다.					
6. 본 지도교사는 재단에서 탐구반 관련 사업자료의 제출 요구 시 성실히 응하겠습니다.					
7. 연구성과물에 대한 저작권 등은 비영리 또는 공익 목적에 한하여 활용할 수 있으며, 탐구반은 재단의 요청 시 해당 결과물의 복제권, 전시권, 배포권, 대여권, 2차 저작물 작성권 등의 저작재산권을 재단에 무상으로 제공하겠습니다.					
2026년 6월 16일					
구분	성명	서명	구분	성명	서명
지도교사	김준우		-	-	-
학생	김서혁		-		
학생	손영우		-		