

2026 주제탐구(R&E) 기초 연구제안서

팀명	어텐션					
과제명	정렬에서의 Grokking: 일반화 조건과 내부 구조 분석					
지도교사	김준우 선생님					
참여 학생	연번	학년	학번	성명	전화번호	확인(서명 또는 날인)
	1	2	251020	김서혁	010-6669-1216	
	2	2	251064	손영우	010-2178-9853	손영우
	3					

☐ 연구비 신청안

항목		산출근거	금액(원)
기기			
소모품			
기타	외부 GPU 대여	Runpod RTX4090 300시간 이내 사용 예정	\$207(\$0.69/hr) = 322,680원
합계			322,680원(환율에 따라 변동 가능)

위와 같이 주제탐구 연구계획서 및 과제 수행을 위한 연구비 신청안을 제출합니다.

대표학생: 손영우 (인장)

지도교사: 김준우



2026년 6월 7일

민족사관고등학교

주제탐구 연구계획서

팀명	어텐션
과제명	정렬에서의 Grokking: 일반화 조건과 내부 구조 분석

1. 서론

가. 이론적 배경

1) Embedding

신경망은 이산적인 기호를 직접 처리할 수 없으므로, embedding을 통해 각 token을 고차원 실수 벡터로 mapping한다. embedding 벡터는 학습 초기에는 무작위로 초기화되지만, 경사 하강법에 의해 갱신되며 점차 token 간의 의미적 유사도가 벡터 공간 내 거리로 반영되는 구조로 수렴한다. 이를 통해 이산 기호에 연속적인 기하학적 구조가 부여되며, 신경망이 이를 연산 가능한 표현으로 처리할 수 있게 된다.

Transformer에서는 두 종류의 embedding이 사용된다. token embedding은 어휘 집합 내 각 기호를 고정 차원의 벡터로 투영하고, positional embedding은 sequence 내 각 position에 대한 정보를 부가적인 벡터로 encoding한다. Self-attention 연산 자체는 입력 순서에 대해 등변(permutation equivariance)을 가지므로, position은 순서 정보를 모델에 명시적으로 주입하기 위한 필수적인 구성 요소이다.

2) Attention

Attention은 sequence 내 임의의 두 position 간 의존 관계를 단일 연산으로 포착하기 위해 도입되었다. 입력 표현은 선형 변환을 통해 Query(Q), Key(K), Value(V)의 세 행렬로 나타난다. 이 연산을 통해 각 position는 sequence 전체를 참조하여 문맥화된 표현으로 갱신되며, 순환 구조 없이도 장거리 의존 관계를 효과적으로 모델링할 수 있다. 이러한 self-attention을 다중 헤드로 병렬 수행하는 Multi-Head Attention이 Transformer의 핵심 연산 단위를 구성한다.

3) Seq2Seq

Seq2Seq(sequence-to-sequence)는 가변 길이의 입력 sequence를 받아 가변 길이의 출력 sequence를 생성하는 구조적 틀이다. Transformer 기반 seq2seq는 encoder-decoder 구조로 구성된다. encoder는 입력 sequence 전체를 self-attention을 통해 문맥화된 잠재 표현으로 압축하고, decoder는 encoder 출력에 대한 cross-attention과 이전 출력 token에 대한 masked self-attention을 조합하여 출력 token을 자기회귀적(auto-regressive)으로 생성한다. 단일 token을 예측하는 분류 문제와 달리, seq2seq는 출력 sequence 전체에 걸쳐 구조적 일관성이 유지되어야 하므로 학습 난이도가 본질적으로 높다.

4) Grokking

Grokking은 Power, Burda, Edwards, Babuschkin, and Misra (2022)이 발견한 지연된 일반화(delayed generalization) 현상으로, 신경망이 훈련 데이터에 대해 완전히 과적합한 이후에도 추가적인 최적화를 지속하면 어느 시점에서 검증 정확도가 급격히 상승하는 현상을 가리킨다. 이는 과적합 이후 추가 학습이 일반화 성능을 개선하지 못한다는 고전적 일반화 이론에 대한 반례를 제시한다.

Nanda, Chan, Lieberum, Smith, and Steinhardt (2023)은 mechanistic interpretability 관점에서 이 현상을 Memorization, Circuit formation, Cleanup의 세 단계로 분리하였다. 학습 초기에는 훈련 데이터를 직접 암기하는 해로 빠르게 수렴하며, 이후 일반화 회로가 가중치 내에서 점진적으로 형성된다. 최종적으로 암기 성분이 소거되면서 일반화 회로만이 잔존하게 되어 검증 정확도가 급등한다. Liu et al.(2022)은 이를 loss landscape 관점에서 분석하여, 훈련 손실과 테스트 손실의 가중치 norm에 대한 형태 불일치(LU mechanism)가 grokking의 근본 원인임을 제시하였다. 암기 해는 일반화 해에 비해 가중치 norm이 크게 유지되므로, weight decay가 모델을 지속적으로 일반화 해 방향으로 유도하는 핵심 기제로 작용한다.

나. 학술적 가치

신경망의 일반화 메커니즘은 딥러닝 이론의 핵심 미해결 문제 중 하나이다. 이 맥락에서 Power et al.(2022)이 발견한 grokking 현상, 즉 신경망이 훈련 데이터를 완전히 암기한 후 한참 지나서야 갑작스럽게 테스트 정확도가 급등하는 지연된 일반화는, 훈련 오차가 충분히 수렴한 이후 추가적인 훈련이 일반화를 오히려 악화시킨다는 고전적 과적합 이론에 반하는 현상으로, 발표 이후 다수의 후속 연구를 촉발하였다.

후속 연구들은 주로 modular arithmetic을 중심으로 진행되어 왔다. Nanda et al.(2023)은 modular addition에서 훈련된 Transformer가 이산 푸리에 변환(discrete Fourier transform)과 삼각 항등식을 이용하여 덧셈을 원 위의 회전으로 변환하는 알고리즘을 내부적으로 학습함을 reverse engineering으로 밝혔으며, 훈련 과정을 Memorization, Circuit Formation, Cleanup의 세 단계로 구분하였다. Varma, Shah, Kenton, Kramár, and Kumar (2023)은 이를 일반화 회로와 암기 회로 간의 효율성 경쟁 관점에서 설명하였고, Liu, Michaud, and Tegmark (2023)은 Omnigrok을 통해 grokking이 알고리즘 데이터셋을 넘어 MNIST, 그래프 데이터 등 다양한 영역에서도 발생함을 보였다. Furuta, Minegishi, Iwasawa, and Matsuo (2024)는 덧셈 이외의 뺄셈, 곱셈, 다항식 등 복합적 modular arithmetic로 분석 범위를 확장하였다.

그러나 기존 연구들은 두 정수 a, b 를 입력으로 받아 $a \odot b \bmod p$ 의 결과를 p 개의 클래스 중 하나로 예측하는 단일 token 분류 문제에 집중하였으며, 수열 전체를 입력으로 받아 재배열된 수열을 출력하는 seq2seq 형태의 구조적 변환에서 grokking이 발생하는지, 그리고 정렬 기준의 대수적 복잡도에 따라 일반화 양상이 어떻게 달라지는지는 거의 탐구되지 않았다. 정렬은 원소 간의 순서 관계를 내재함으로써 단순한 입출력 대응을 넘어 수열 전체의 구조를 파악해야 한다는 점에서, 기존 modular arithmetic 연구와 본질적으

로 다른 모델 구조를 가진다. 또한 $(\text{mod } m)$ 에 대한 오름차순 정렬이나 최솟값-최댓값 교번 정렬처럼 일부 정렬 기준은 잉여류 구조를 정렬 키로 내포하므로, modular arithmetic 과 주기적 구조를 공유한다. 본 연구는 이 유사성이 모델 내부 표현에서 실제로 재현되는지를 검증 대상으로 삼는다.

또한 본 연구는 positional embedding과 token embedding이 정렬 알고리즘 학습에서 각각 어떤 역할을 하는지, 그리고 실질적으로 유효한 표현 차원의 수가 몇 개인지를 분석함으로써, Transformer 내부의 표현 학습 메커니즘에 대한 이해를 심화시키는 데 기여할 수 있다.

다. 연구의 독창성

기존 연구는 두 정수의 연산 결과를 단일 토큰으로 예측하는 분류 문제에 집중하였으나, 본 연구는 길이 N 의 수열을 입력으로 받아 재배열된 수열 전체를 출력하는 seq2seq 구조에 초점을 둔다. 이는 grokking 연구에서 출력이 구조화된 sequence인 경우를 다루는 시도이다.

본 연구는 정렬 기준을 서로 독립적인 두 정렬 축에서 설계한다는 점에서 차별성을 가진다. 첫째 축은 정렬 키의 대수적 구조로, 값을 그대로 사용하는 항등 키(오름차순)에서 잉여류 구조를 키로 내포하는 $(\text{mod } m)$ 기반 키로 확장된다. 둘째 축은 순위에서 출력 위치로의 매핑 구조로, 단조 매핑(오름차순)에서 비단조 매핑(최솟값-최댓값 교번 정렬)으로 확장된다. 기존 연구가 modular arithmetic이라는 단일 대수 구조에 한정되었던 것과 달리, 본 연구는 이 두 축을 분리함으로써 정렬 규칙의 어떤 구조적 속성이 grokking과 연관되는지를 귀납적으로 탐색한다.

또한 본 연구는 encoder와 decoder 각각에서 positional embedding과 token embedding 중 어느 쪽이 일반화에 더 결정적인지, 표현의 유효 차원 수는 몇 개인지를 함께 분석함으로써 단순한 현상 확인을 넘어 내부 구조의 규명을 시도한다. 특히 정렬 함수는 입력 순서에 대해 불변(permutation invariant)이지만 출력은 순서를 가진다는 비대칭성에 주목하여, encoder와 decoder에서 positional embedding의 필요성이 서로 다르게 나타나는지를 정렬 과제에서 분리 검증한다.

본 연구는 Urdshals and Urdshals(2025)가 단층 attention-only Transformer의 학습 완료 후 내부 attention 구조를 분석한 것과 달리, grokking이라는 지연된 일반화 현상 자체의 발현 여부와 그 과정에서 내부 표현이 어떻게 변화하는지에 초점을 둔다는 점에서 구별된다.

2. 연구 문제(Research Question)

가. [연구 문제 1] Seq2Seq 정렬에서 Grokking이 발현되는가, 그리고 정렬 규칙의 구조는 그 발현 양상에 어떤 영향을 주는가?

기존 grokking 연구는 단일 토큰 분류(modular arithmetic)에 집중되어 있어, 출력이 순서를 갖는 seq2seq 구조적 변환에서도 grokking이 동일하게 발현되는지는 아직 규명되지 않았다. 본 연구는 먼저 정렬 과제에서 grokking, 즉 훈련 정확도가 포화된 이후 한참 뒤에 검증 정확도가 급등하는 지연된 일반화가 실제로 발현되는지를 확인한다. 이를 위해 서로 독립적인 두 축에서 정렬 기준을 설계한다. 정렬 키 축에서는 값을 그대로 사용하는 전순서 기반 오름차순 정렬과 mod m 잉여류 체계를 키로 내포하는 (mod m)에 대한 오름차순 정렬을, 출력 위치 매핑 축에서는 단조 매핑(오름차순)과 비단조 매핑(최솟값-최댓값 교번 정렬)을 둔다. 각 기준에 대해 모델 크기·learning rate·weight decay·입력 길이 N ·정수 크기 p ·train fraction을 고정한 통제된 조건에서 최소 5개 이상의 시드로 훈련시킨다. 정렬 기준 간 내재적 난이도 차이를 고려하여, raw step 수뿐 아니라 훈련 정확도 포화 시점으로 정규화한 상대적 grokking gap도 함께 확인한다. 단, grokking은 hyperparameter와 weight decay에 민감하므로 발현되지 않을 수 있으며, 이 경우 "정렬 과제에서는 grokking이 관찰되지 않는다" 또는 "어떤 구조에서 grokking이 관찰되지 않는가" 역시 유의미한 결과로 해석한다. 나아가 단일 토큰 분류에서 관찰된 memorization $\rightarrow$ circuit formation $\rightarrow$ cleanup의 전이가 출력 시퀀스 전체의 일관성이 요구되는 seq2seq 정렬에서도 동일하게 재현되는지를 검토하고, 정렬 규칙의 구조(정렬 키 / 위치 매핑)에 따라 발현 여부와 시점이 어떻게 달라지는지를 비교한다.

나. [연구 문제 2] grokking 이후 모델의 내부 표현은 어떤 구조를 가지는가?

Nanda et al.(2023)은 modular addition에서 grokking이 완료된 모델이 푸리에 기저를 활용한 소수의 주파수 성분만으로 연산을 수행함을 보였다. 이는 일반화 이후 모델의 내부 표현이 과제 구조에 부합하는 저차원 기하학적 구조로 수렴할 수 있음을 시사한다. 다만 modular addition의 푸리에 구조는 순환군상의 합성 연산에서 비롯되는 반면, 정렬은 원소 간 비교와 라우팅을 핵심으로 하므로 동일한 저차원 수렴이 나타나지 않을 수 있다. 따라서 본 연구는 저차원 수렴을 전제하지 않고, grokking 완료 모델의 내부 표현이 어떤 구조를 갖는지를 다음 단계로 탐색한다. 먼저 token embedding 행렬과 잔차 스트림 활성화에 PCA를 적용하여 유효 차원 수를 측정하고, 정렬 키에 주기 구조가 도입된 기준에서는 이산 푸리에 변환으로 주기성이 표현에 반영되는지를 검사한다. 푸리에 구조가 나타나지 않을 경우 군집 구조, 계층적 선형 구조, 잉여류에 대한 선형 분리 가능성 순으로 대안적 구조를 탐색한다.

다. [연구 문제 3] seq2seq 정렬에서 positional embedding과 token embedding은 일반화에 대해 각각 어떠한 기여를 가지는가?

정렬은 원소의 값뿐 아니라 출력 시퀀스 내 위치 관계를 동시에 학습해야 하므로, token embedding과 positional embedding이 일반화에 기여하는 방식이 분류와 본질적으로 다를 수 있다. 정렬 함수는 입력 순서에 대해 불변(permutation invariant)이지만 출력은 순서를 가진다는 비대칭성에 주목한다. 이로부터 encoder의 positional embedding은 일반화에 불필요하거나 오히려 해로울 수 있는 반면, decoder의 positional embedding은 출

력 순서를 결정하는 데 기여한다는 가설을 세운다. 다만 decoder의 의존도는 정렬 기준에 따라 다를 수 있다. 단조 매핑(오름차순)은 "지금까지 출력한 값 중 최댓값"과 같은 내용 기반 상태만으로 다음 토큰을 결정할 수 있어 positional embedding 없이도 학습될 여지가 있는 반면, 비단조 매핑(교번 정렬)은 출력 위치의 홀짝에 규칙이 의존하므로 절대 위치 정보가 결정적일 것으로 예상된다. 이를 검증하기 위해 학습형 절대 위치 임베딩을 기준선으로 하여 positional embedding을 encoder/decoder로 분리해 제거하는 ablation을 수행하고, 조건 간 대비를 통해 가설을 직접 검증한다. 특히 정렬 기준에 따라 두 embedding의 상대적 기여도가 달라지는지를 함께 분석함으로써, 정렬 규칙의 구조가 표현 학습 메커니즘에 어떻게 반영되는지를 확인한다.

3. 선행연구 조사

가. Transformer Model의 기본원리가 되는 연구

- 1) Vaswani et al. (2017)은 "Attention Is All You Need"에서 self-attention을 기반으로 한 Transformer architecture를 제안하였다. 이후 grokking 연구들은 주로 small Transformer를 알고리즘에 학습시켜 내부 표현과 일반화된 과정을 분석하므로, 이 연구는 본 연구에서 사용하는 model architecture의 기반이 된다.

나. grokking 현상을 체계적으로 제시한 연구

- 1) Power et al. (2022)은 "Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets"에서 인공 신경망이 작은 algorithmic dataset을 먼저 memorization한 뒤, 긴 optimization 이후 갑자기 일반화를 달성하는 grokking 현상을 보고하였다. 이는 모델이 단순 암기를 넘어 데이터의 기저를 학습할 수 있음을 보여주며, 본 연구의 기반이 된다.
- 2) Nanda et al. (2023)은 "Progress Measures for Grokking via Mechanistic Interpretability"에서 modular addition을 학습한 small transformer가 Fourier basis와 trigonometric identities를 활용해 일반화하는 내부 알고리즘을 reverse engineering하였다. 이 연구는 grokking을 단순한 갑작스러운 성능 변화가 아니라, structured mechanism의 점진적 형성과 memorizing component의 제거가 결합된 과정으로 해석하였다.




Fig 1. Grokking 현상으로 인한 학습량에 따른 Train/Test Accuracy의 변화

다. grokking 분석을 다양한 algorithmic task로 확장한 연구

- 1) Chughtai, Chan, and Nanda (2023)은 "A Toy Model of Universality: Reverse Engineering How Networks Learn Group Operations"에서 small neural networks가 finite group composition을 수행할 때 representation theory 기반 알고리즘을 학습할 수 있음을 mechanistic interpretability로 분석하였다. 이 연구는 modular addition 중심의 해석을 group-theoretic algorithmic task로 확장하며, 모델들이 유사한 원리를 학습할 수 있지만 세부 circuits와 학습 순서는 달라질 수 있음을 보여준다.
- 2) Furuta et al. (2024)은 "Towards Empirical Interpretation of Internal Circuits and Properties in Grokked Transformers on Modular Polynomials"에서 grokking 분석 대상을 modular addition에서 subtraction, multiplication, modular polynomials, multi-task mixture로 확장하였다. 이들은 Fourier Frequency Density(FFD)와 Fourier Coefficient Ratio(FCR)라는 progress measure를 제안하여 operation별 internal representation의 차이를 분석했으며, factorizable polynomials에서는 grokking이 비교적 잘 발생하지만 non-factorizable polynomials에서는 명확한 Fourier pattern이 나타나지 않는 경우가 있음을 보였다.
- 3) Stander, Yu, Fan, and Biderman (2024)은 "Grokking Group Multiplication with Cosets"에서 permutation group의 group multiplication을 학습한 one-hidden-layer network를 reverse engineering하였다. 이 연구는 group operation을 학습한 인공 신경망의 내부 표현을 coset structure와 연결하여 분석했다는 점에서, group-theoretic task에서의 grokking 해석을 확장한다.

라. Transformer의 sorting task 학습과 내부 구조 분석 연구

- 1) Urdshals and Urdshals (2025)은 "Structure Development in List-Sorting Transformers"에서 one-layer attention-only Transformer가 number list sorting을 학습하는 과정에서 내부 attention 구조가 어떻게 발달하는지 분석하였다. 이 연구는 학습이 끝난 모델의 attention heads가 vocabulary-splitting과 copy-suppression이라는 두 가지 주요 방식으로 조직됨을 보였으며, 본 연구의 다양한 방법의 정수 정렬에서 model이 단순 memorization을 넘어 어떤 내부 구조를 형성하는지 해석하는 데 참고가 된다.

4. 연구내용

가. 연구 개요 및 실험 패러다임

본 연구는 길이 N 의 정수 수열을 입력으로 받아, 정해진 정렬 기준에 따라 재배열된 수열 전체를 출력하는 seq2seq 정렬 과제에서 grokking이 발현되는지, 그리고 정렬 규칙의 구

조가 일반화의 양상과 내부 표현에 어떻게 반영되는지를 실험적으로 규명한다. 기존 grokking 연구가 두 정수 a, b 에 대해 $a \odot b \bmod p$ 를 p 개 클래스 중 하나로 예측하는 단일 token 분류에 한정되었던 것과 달리, 본 연구는 출력이 순서를 갖는 시퀀스 전체인 경우로 패러다임을 확장한다.

연구는 세 단계로 구성된다. 첫째(연구 문제 1), 정렬 키와 출력 위치 매핑이라는 두 독립적인 축에서 설계한 정렬 기준들에 대해 동일한 조건으로 Transformer를 훈련하여, grokking의 발현 여부와 발현 시점, 그리고 일반화 지연의 정도(grokking gap)를 비교한다. 둘째(연구 문제 2), grokking이 완료된 모델의 내부 표현을 추출하여 유효 차원 수와 그 기하학적·회로적 구조를 분석한다. 셋째(연구 문제 3), positional embedding과 token embedding에 대한 ablation을 통해 각 표현 요소가 일반화에 기여하는 방식을 정렬 기준 별로 분리 측정한다.

특히 본 연구는 grokking의 발현을 전제하지 않는다. grokking은 암기가 가능한 소규모 데이터, 강한 weight decay, 지연된 일반화라는 특수 조건에서만 관찰되므로, 정렬 과제에서 grokking이 발현되지 않거나 정렬 기준에 따라 발현 여부가 갈리는 것 자체가 유의미한 결과로 해석한다.

나. 정렬 과제 및 데이터셋 설계

1) 입력·출력의 정의

어휘(값) 집합을 $V = \{0, 1, \dots, p-1\}$ 로 둔다. 즉 수열에 등장하는 정수는 0부터 $p-1$ 까지이다. 입력은 이 집합에서 뽑은 길이 N 의 정수 수열 $x = (x_1, \dots, x_N) \in V^N$ 이며, 같은 값이 중복될 수 있다. 정렬 결과는 원소의 순서가 아니라 어떤 값들이 들어 있는지에만 의존하므로, 입력은 순서 없는 모음(multiset)으로 간주한다. 출력은 정해진 정렬 기준에 따라 이 수열을 재배열한 결과이다.

입력 수열에는 시작·끝과 입출력 경계를 표시하는 특수 token인 BOS(시작), EOS(끝), SEP(구분자)를 함께 붙여 토큰화한다. 출력은 decoder가 자기회귀적으로 한 토큰씩 생성한다. 손실은 모델의 예측과 정답의 차이를 재는 cross-entropy를 출력 토큰 위치 전체에 대해 합산하여 정의한다.

2) 세 가지 정렬 기준

정렬 기준은 서로 독립적인 두 축에서 설계한다. 정렬 키 축은 값을 그대로 쓰는지(항등) 가공하는지(주기)를, 출력 위치 매핑 축은 순위와 출력 위치의 대응이 단조인지 비단조인지를 가른다. 세 기준은 입력 분포와 입출력 길이를 동일하게 공유하므로, 차이는 오직 정렬 규칙의 구조에서만 비롯된다.

기준 A - 오름차순 정렬 (키: 항등 / 매핑: 단조)

값을 오름차순으로 정렬한다. 예: $(3, 1, 4, 1, 5) \rightarrow (1, 1, 3, 4, 5)$. 핵심 구조는 원소 간 비교이며, grokking 발현의 기준선 역할을 한다.

기준 B - 잉여류 기반 정렬 (키: 주기 / 매핑: 단조)

1차 키를 $x \pmod{m}$, 2차 키를 x 로 하여 오름차순 정렬한다(잉여류가 작은 원소가 먼저, 같은 잉여류 안에서는 오름차순). 예: $m=3$ 일 때 $(3, 1, 4, 1, 5) \rightarrow (3, 1, 1, 4, 5)$. 정렬 키에 $\pmod{m}$ 의 잉여류 체계가 내포된다. 본 연구는 이 기준에서 내부 표현이 modular arithmetic 연구(Nanda et al., 2023)의 Fourier형 주기 구조를 재현하는지를 검증 대상으로 하되, 재현되지 않을 가능성도 함께 분석한다.

기준 C - 최솟값-최댓값 교번 정렬 (키: 항등 / 매핑: 비단조)

오름차순으로 정렬한 뒤 최솟값·최댓값·2번째 최솟값·2번째 최댓값... 순으로 교번 재배열한다. 예: $(3, 1, 4, 1, 5) \rightarrow (1, 1, 3, 4, 5) \rightarrow (1, 5, 1, 4, 3)$. 순위와 출력 위치가 단조 관계를 이루지 않으므로, 모델은 값의 순위(rank)와 출력 위치 간의 비단조 대응을 학습해야 한다.

3) Grokking 관찰을 위한 데이터

grokking은 (i) 훈련셋에 대한 암기가 가능하면서, (ii) 일반화가 지연되는 환경에서만 관찰된다. 입력 공간 $|V|^N$ 이 조합적으로 폭발하면 암기가 불가능해져 grokking 대신 일반적인 학습이 일어나므로, 본 연구는 정수 크기와 길이를 작게 제한한다. 구체적으로 $V \approx 10$ -12, $N \approx 5$ -6을 후보로 하면 입력 공간이 약 10^5 - 10^6 규모가 되어, 소규모 Transformer가 훈련셋을 암기할 수 있으면서 동시에 일반화를 측정할 검증셋도 확보된다. 다만 구체적인 수치는 본 실험에서 충분히 변경될 수 있다.

전체 입력 집합을 일정 비율만 훈련셋으로, 나머지를 검증셋으로 무작위 분할한다. 단, 정렬 출력은 입력의 순서가 아니라 multiset에만 의존하므로, 분할은 multiset 단위로 수행한다. 이렇게 하면 검증셋의 어떤 입력도 그 순열이 훈련셋에 등장하지 않아, 모델이 처음 보는 값 조합에 대한 일반화를 측정하게 된다.

train fraction은 0.3-0.8 범위에서 변화시켜 비율에 따른 grokking이 나타나는 정도를 조사한다. 이 비율은 grokking 발현 시점에 결정적 영향을 미치므로, 모든 정렬 기준에서 동일한 비율 집합을 사용하여 비교의 합리성을 확보한다.

다. 모델 구조 및 학습 설정

모델은 Vaswani et al.(2017)의 encoder-decoder Transformer를 소규모로 구성한다(단, 연구 진행 과정에 따라 기반으로 하는 Transformer는 변경할 수 있다). 최적화는 grokking 유도에 핵심적인 weight decay를 강하게 적용한 AdamW를 사용하며, full-batch 또는 large batch로 최대 10^6 step까지 장기 학습한다. weight decay는 암기해(큰 가중치 norm)에서 일반화해(작은 norm)로 모델을 유도하는 기제(Liu et al., 2022의 LU mechanism)이므로, 그 강도가 grokking 발현에 미치는 영향을 별도로 분석한다. 이때 단일 고정값으로 비교하면 기준별 최적 weight decay가 달라 일부 기준에서만 grokking이 억제될 수 있으므로, weight decay 축에 걸친 phase diagram(Liu et al., 2022; Liu et al., 2023)으로 각 기준의 grokking 발현 영역을 비교한다. 어느 기준이 더 넓은 weight decay 구간에서 grokking하는지가 발현 난이도의 더 안정적인 지표가 된다. 정렬 기준 간 비교의 공정성을 위해 model size, learning rate, batch size, 초기화 스케일, 입력 길이 N , 정수 크기 p , train fraction을 모든 조건에서 동일하게 고정한다. 단

weight decay는 위와 같이 의도적으로 조정하는 분석 대상 변인이므로 고정 대상에서 제외한다. grokking 발현 시점은 무작위 시드에 따른 분산이 크므로, 각 (정렬 기준 $\times$ 설정) 조합에 대해 최소 5개 이상의 시드로 반복 실험하여 분포로 보고한다.

5. 연구 방법 및 예상 결과

가. 연구 방법

1) [연구 문제 1] 정렬 기준별 grokking 발현·수렴 비교

각 정렬 기준에 대해 훈련 step에 따른 훈련/검증 정확도 곡선을 기록한다. seq2seq 과제이므로 두 가지 정확도를 함께 측정한다: 출력 시퀀스 전체가 정확히 일치하는 시퀀스 단위 exact-match 정확도와, 위치별 token이 일치하는 token 단위 정확도이다. 전자는 구조적 일관성을, 후자는 부분적 학습 진행을 포착한다. 단, 검증 정확도는 teacher forcing 없이 자기회귀 decoding으로 측정하여 실제 생성 성능을 반영하도록 한다.

grokking 발현의 조작적 정의: 훈련 정확도가 포화(예: 99.5% 이상)된 step t_{train} 과, 검증 exact-match 정확도가 임계값(예: 95%)을 처음 초과하는 step t_{val} 을 각각 확인하고, 그 간격 $\Delta = t_{\text{val}} - t_{\text{train}}$ 을 grokking gap으로 정의한다. Δ 가 클수록 일반화가 더 지연됨을 의미한다. 최대 step까지 검증 정확도가 임계값에 도달하지 못한 경우는 grokking이 관찰되지 않은 것으로 기록한다.

교란변인 분리:

정렬 기준에 따른 알고리즘 난이도가 상이하므로, raw step 수의 단순 비교는 정렬 규칙의 구조적 효과와 알고리즘 난이도를 혼동할 위험이 있다. 이를 완화하기 위해 (i) 훈련 정확도가 포화되는 시점으로 정규화한 상대적 gap, (ii) 동일 train fraction에서의 발현 여부(이진 결과)를 함께 조사한다.

통계 처리:

발현 시점(time-to-grok)은 일부 시드가 끝까지 grok하지 않는 중도절단 데이터이므로, 단순 평균 비교 대신 Kaplan-Meier 생존곡선으로 시각화하고 기준 간 차이는 log-rank 검정으로 평가한다. 시드 간 분산은 박스플롯으로 함께 제시한다. 이를 통해 "정렬 규칙의 어떤 구조적 속성이 grokking을 더 어렵게/쉽게 만드는가"를 귀납적으로 탐색한다.

2) [연구 문제 2] grokking 이후 내부 표현 분석

grokking이 완료된 모델에서 token embedding 행렬과 잔차 스트림(residual stream) 활성을 추출하여 내부 표현의 구조를 분석한다. 잔차 스트림은 분석 대상 층과 위치를 명시하여 추출하며, 기본적으로 encoder 마지막 층의 각 입력 위치 활성을 사용한다.

유효 차원 측정:

표현 행렬에 PCA를 적용하여, 누적 분산의 일정 비율(예: 90%, 95%)을 설명하는 데 필요한 주성분 수, 그리고 participation ratio PR 를 계산하여 표현이 얼마나 저차원으로 압축되었는지를 정량화한다. 다만 modular addition에서 관찰된 저차원 수렴은 순환군상

의 합성 연산에서 비롯된 것이므로, 비교·라우팅을 핵심으로 하는 정렬에서 동일한 수렴이 나타난다고 전제하지 않고 측정한다.

기준별 예상 구조 및 검증:

기준 A(키: 항등 / 매핑: 단조)에서는 token embedding이 값의 크기에 따라 일렬로 배열되는 거의 1차원적 수직선 구조를 예상한다.

기준 B(키: 주기 / 매핑: 단조)에서는 token embedding에 이산 푸리에 변환(DFT)을 적용하여 modular arithmetic에서 관찰된 것과 같은 주기 구조가 나타나는지를 검사하고, Furuta et al.(2024)의 Fourier Frequency Density(FFD)를 progress measure로 활용하여 정량 비교한다. 단, 작은 V 에서는 모델이 $x \bmod m$ 을 산술적으로 계산하지 않고 lookup으로 처리해 주기 구조가 나타나지 않을 수 있다. 이 경우 군집 구조(잉여류별 임베딩 군집화), 계층적 선형 구조(잉여류별 평행 직선), 잉여류에 대한 선형 분리 가능성(linear probing) 순으로 대안적 구조를 탐색한다.

기준 C(키: 항등 / 매핑: 비단조)에서는 값의 순위와 출력 위치 간 비단조 대응이 표현에 어떻게 인코딩되는지를 분석한다.

attention 회로 분석:

정렬에서는 표현이 임베딩 기하뿐 아니라 attention 패턴에 나타날 수 있으므로, 각 출력 위치가 어느 입력을 참조하는지를 분석한다. Urdshals and Urdshals(2025)가 보고한 vocabulary-splitting·copy-suppression 패턴이 나타나는지를 확인하여, 표현이 임베딩 기하와 attention 회로 중 어느 쪽에 주로 의존하는지 평가한다.

3) [연구 문제 3] Embedding Ablation

정렬은 입력 원소의 값뿐 아니라 출력 시퀀스 내 위치 관계를 동시에 학습해야 하므로, 두 종류 embedding의 역할이 단일 token 분류와 본질적으로 다를 수 있다. 정렬 함수는 입력 순서에 대해 불변이지만 출력은 순서를 가진다는 비대칭성이 존재한다.

이로부터 다음의 가설을 세운다.

encoder 측 positional embedding은 일반화에 불필요하거나 오히려 해로울 수 있는 반면, decoder 측 positional embedding은 출력 순서를 결정하는 데 기여한다. 단 decoder의 의존도는 정렬 기준에 따라 다를 수 있어, 단조 매핑(오름차순)은 "지금까지 출력한 값 중 최댓값"과 같은 내용 기반 상태만으로 다음 토큰을 결정할 수 있는 반면, 비단조 매핑(교번 정렬)은 출력 위치의 홀짝에 규칙이 의존하므로 절대 위치 정보가 결정적일 것으로 예상된다.

이를 검증하기 위해, 학습형 절대 위치 임베딩을 사용하는 기준선을 기준으로 다음 조건들을 비교한다.

(C0) 전체 모델: 학습형 token + 학습형 절대 위치 임베딩(기준).

(C1) positional embedding 전면 제거.

(C2) encoder positional embedding만 제거.

(C3) decoder positional embedding만 제거.

(C4) token embedding을 고정(one-hot 또는 무작위 고정)으로 대체.

각 조건에서 grokking 발현 여부, grokking gap, 최종 exact-match 정확도를 측정한다. C2와 C3의 대비를 통해 위의 비대칭 가설을 직접 검증하며, C4를 통해 학습형 token embedding이 일반화에 필수적인지를 확인한다. 나아가 동일한 ablation을 세 정렬 기준 각각에 적용하여, 각 embedding의 상대적 기여도가 정렬 규칙의 구조에 따라 달라지는지를 분석한다. 잉여류 기준에서는 주기 구조를 인코딩하는 token embedding이, 교번 기준에서는 출력 위치를 인코딩하는 decoder positional embedding이 상대적으로 더 결정적일 것으로 예상된다.

조건 간(C0~C4) 최종 exact-match 정확도와 grokking 발현 여부의 차이는 시드 표본에 대한 비모수 검정으로 평가하며, 발현 시점 비교에는 *연구문제1* 과 동일하게 Kaplan-Meier 생존곡선과 log-rank 검정을 적용한다. 특히 C2(encoder PE 제거)와 C3(decoder PE 제거)의 대비를 정렬 기준별로 비교하여, PE 비대칭 가설이 기준에 따라 어떻게 달라지는지를 확인한다.

나. 예상 결과

- 1) 정렬 규칙의 구조가 복잡해질수록 grokking gap이 커지거나 발현이 어려워질 것으로 예상된다. 구체적으로 정렬 키에 주기 구조가 도입된 기준(잉여류)과 출력 위치 매핑이 비단조인 기준(교번)에서, 두 축 모두 단순한 기준선(오름차순)보다 일반화가 더 지연되거나 더 좁은 weight decay 구간에서만 발현될 것으로 예상된다.
- 2) 잉여류 기준의 내부 표현에서 modular arithmetic과 유사한 Fourier형 주기 구조가 재현될 가능성이 있다. 다만 정렬은 잉여류를 산술적으로 합성하는 것이 아니라 키로 계산해 그룹핑하는 과제이므로, 주기 구조 대신 잉여류별 군집이나 계층적 선형 구조로 나타났거나, lookup 기반으로 처리되어 뚜렷한 구조가 관찰되지 않을 가능성도 함께 생각한다.
- 3) decoder positional embedding이 encoder positional embedding보다 일반화에 더 결정적일 것으로 예상된다. 단 decoder의 의존도는 기준에 따라 달라, 단조 기준에서는 내용 기반 상태로 일부 대체될 수 있는 반면 비단조 기준(교번)에서는 절대 위치 정보가 결정적일 것으로 예상된다.

다. 한계점

- 1) grokking은 hyperparameter, 특히 weight decay와 데이터 규모에 민감하여 의도한 조건에서도 발현되지 않을 수 있다. 이 경우에도 "어떤 구조에서 grokking이 사라지는가"라는 형태로 결과를 해석한다. 특히 정렬은 비교·라우팅이라는 일반화 해가 inductive bias상 비교적 유리한 과제일 수 있어, 기준선조차 grokking 없이 곧바로 일반화될 가능성이 있다. 이 경우 grokking 유도 자체가 어려운 과제 특성으로 여겨진다.
- 2) 세 정렬 기준의 내재적 알고리즘 난이도 차이를 완전히 제거할 수는 없다. 정규화된 상대적 gap과 발현 여부(이진 결과)로 이를 완화하고, 발현 시점은 일부 시드가 끝까지

grok하지 않는 중도절단을 고려해 생존분석으로 다루지만, 그럼에도 결론은 절대적 수렴 시점이 아니라 통제된 조건 하의 상대적 비교로 한정하여 제시한다.

- 3) 본 연구는 작은 정수 크기와 짧은 길이로 입력을 제한하고 multiset 단위로 데이터를 분할하므로, 결과는 이 소규모 설정에 한정된다. 더 긴 수열에 대한 길이 외삽(length generalization)이나 큰 어휘 집합으로의 확장은 본 연구의 범위를 벗어나며, 향후 과제로 남긴다.

5. 참고문헌

- Chughtai, B., Chan, L., & Nanda, N. (2023). A toy model of universality: Reverse engineering how networks learn group operations. In Proceedings of the 40th International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 202, pp. 6243-6267). PMLR.
- Furuta, H., Minegishi, G., Iwasawa, Y., & Matsuo, Y. (2024). Towards empirical interpretation of internal circuits and properties in grokked Transformers on modular polynomials. Transactions on Machine Learning Research.
- Liu, Z., Kitouni, O., Nolte, N. S., Michaud, E. J., Tegmark, M., & Williams, M. (2022). Towards understanding grokking: An effective theory of representation learning. In Advances in Neural Information Processing Systems (Vol. 35, pp. 34651-34663). Curran Associates, Inc.
- Liu, Z., Michaud, E. J., & Tegmark, M. (2023). Omnigrok: Grokking beyond algorithmic data. In International Conference on Learning Representations.
- Nanda, N., Chan, L., Lieberum, T., Smith, J., & Steinhardt, J. (2023). Progress measures for grokking via mechanistic interpretability. In International Conference on Learning Representations.
- Power, A., Burda, Y., Edwards, H., Babuschkin, I., & Misra, V. (2022). Grokking: Generalization beyond overfitting on small algorithmic datasets. arXiv preprint arXiv:2201.02177.
- Stander, D., Yu, Q., Fan, H., & Biderman, S. (2024). Grokking group multiplication with cosets. In Proceedings of the 41st International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 235, pp. 46441-46467). PMLR.
- Urdshals, E., & Urdshals, J. (2025). Structure development in list-sorting Transformers. arXiv preprint arXiv:2501.18666.
- Varma, V., Shah, R., Kenton, Z., Kramár, J., & Kumar, R. (2023). Explaining grokking through circuit efficiency. arXiv preprint arXiv:2309.02390.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (Vol. 30, pp. 5998-6008). Curran Associates, Inc.

주제탐구 연구추진 일정표

추진일정	연구추진계획	(세부) 연구 내용
09월 초	연구 준비	기존 연구에서 사용된 Transformer model 탐색 및 이해
09월 말	Transformer model 제작	기존 연구의 Transformer model을 본 연구에 맞는 seq2seq로 변경
10월 초	예비 실험	제작한 Transformer model 테스트 및 수정 & Grokking 현상 유무 확인
10월 말	본 실험	연구문제 해결을 위한 실험 진행
11월 초	마무리	실험결과 정리 & 보고서 및 발표 자료 제작
11월 말	발표	발표
12월 초		
12월 말		

연구윤리 및 AI 활용 선언문

“훌륭한 연구자는 결과보다 과정을 더 소중히 여깁니다.”

본 활동지는 본격적인 연구 시작 전, 연구자로서 갖춰야 할 정직성과 책임감을 스스로 확인하고 서약하는 문서입니다. 작성된 내용은 향후 연구보고서의 첫 페이지 또는 부록에 수록될 수 있습니다.

1. 연구 부정행위(FFP) 자가 점검

연구 부정행위의 개념을 확인하고, 이를 절대 하지 않겠다는 확인란에 체크(✓) 하세요.

[✓] 위조 (Fabrication): 존재하지 않는 데이터나 연구 결과를 허위로 만들어 내는 행위

[✓] 변조 (Falsification): 연구 재료, 장비, 과정을 인위적으로 조작하거나 데이터를 임의로 변형/삭제하여 결과를 왜곡하는 행위

[✓] 표절 (Plagiarism): 타인의 아이디어, 연구 과정, 결과 등을 적절한 출처 표기 없이 도용하는 행위

[✓] 부당한 저자 표시: 연구에 기여하지 않은 사람을 저자로 포함하거나, 기여한 사람을 제외하는 행위

2. 생성형 AI(Generative AI) 활용 허용 범위 설정 (Make Rules)

한국연구재단 권고사항에 의거하여, 우리 팀이 준수할 AI 활용의 'Green Light(허용)'와 'Red Light(금지)' 기준을 직접 정해봅시다.

허용 범위 (Green Light) - “우리는 AI를 이렇게 돕는 도구로만 쓰겠습니다.”

(예시: 아이디어 브레인스토밍, 영문 초록 문법 교정, 코딩 에러 수정 등)

1. 논문 검색 및 선행연구 요약 보조

2. Python/PyTorch 코드 디버깅 및 구현 오류 수정 보조

3. 보고서·발표자료의 문법 교정 및 표현 다듬기

금지 범위 (Red Light) - “이 영역은 오직 인간 연구자의 몫입니다.”

(예시: 실험 데이터값 생성, 존재하지 않는 참고문헌 생성, 결론 및 고찰의 전체 대필 등을 하지 않겠습니다.)

1. [필수] 실험/관측 데이터의 임의 생성 및 조작을 하지 않겠습니다.

2. 직접 확인하지 않은 참고문헌을 생성, 인용을 하지 않겠습니다.

3. 전체 대필 및 이해하지 못한 코드 생성을 하지 않겠습니다.

AI 사용 시 출처 표기 방식 약속

우리는 생성형 AI를 사용했을 경우, 보고서(연구노트)에 다음과 같이 투명하게 밝히겠습니다.

[작성 예시] 본 연구의 실험 설계 단계에서 아이디어 확장을 위해 'ChatGPT-4o'를 활용하였으며, 사용한 프롬프트는 "물리실험 변인 통제 아이디어 제안해줘"입니다.

3. 예비 연구자 윤리 선언 (Declaration)

나는 민족사관고등학교의 예비 과학자로서 다음의 사항을 엄숙히 선언합니다.

나는 연구의 모든 과정에서 데이터를 투명하게 기록하며, 어떠한 경우에도 위조와 변조를 하지 않겠습니다.

나는 타인의 지적 재산권을 존중하며, 인용한 모든 자료의 출처를 명확히 표기하겠습니다.

나는 생성형 AI를 연구의 보조 도구로만 활용하며, AI가 산출한 결과의 사실 여부(Fact-check)를 반드시 내가 직접 검증하겠습니다.

나는 동료 연구자와 협력하며, 연구의 공적 가치를 훼손하는 행동을 하지 않겠습니다.

본인은 위 내용을 충분히 숙지하였으며, 이를 어길 시 관련 규정에 따른 어떠한 불이익도 감수할 것을 서약합니다.

2026년 6월 8일

연구자(본인): 김서혁 (인명), 손영우 (인명) (지도교사 확인): 김준우 (인명)